TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Image Decomposition trong Image Fusion

Tổng hợp Lý thuyết SOTA 2022 – 2025

Đỗ Trung Kiên

Ngày 3 tháng 4 năm 2026

ONE LOVE. ONE FUTURE

Giới thiệu tổng quan
Nhóm 1: Multi-scale Transform Decomposition
- Discrete Wavelet Transform (DWT)
- Non-subsampled Shearlet Transform (NSST)
- Gaussian / Laplacian Pyramid
- Guided Filter & Edge-Preserving
- WMambaFuse (2025)

Nhóm 2: Feature Decomposition (Deep Learning)
- CDDFuse (CVPR 2023)
- Modality-Specific / Shared Decomposition

Nhóm 3: Generative / Diffusion-based Decomposition
- DDPM
- DDFM (ICCV 2023)

Nhóm 4: Physical-Prior Decomposition
- Retinex Decomposition
- Hilbert Vibration Decomposition (HVD)

Nhóm 5: INN / Flow-based

Image Fusion là bài toán kết hợp thông tin từ nhiều ảnh nguồn khác modality (IR + VIS, MRI + CT, multifocus...) nhằm tạo ra **một ảnh duy nhất** chứa đầy đủ thông tin bổ sung.

Ứng dụng tiêu biểu: Giám sát an ninh, chẩn đoán y tế, xe tự lái, viễn thám, robotics.

Image Decomposition là thành phần **then chốt** trong hầu hết pipeline fusion SOTA.

Ý tưởng cốt lõi

Phân tách ảnh nguồn thành các thành phần độc lập $\rightarrow$ áp dụng chiến lược fusion tối ưu cho từng thành phần $\rightarrow$ tổng hợp lại ảnh kết quả.

Trong fusion, hai loại thông tin cần xử lý khác nhau:

- **Base / Low-frequency:** Thông tin cường độ nền, cấu trúc toàn cục (illumination, large-scale structure).
  $\Rightarrow$ Yêu cầu tích hợp nhất quán, tránh artifact.
- **Detail / High-frequency:** Cạnh, kết cấu, gradient cục bộ, nhiễu.
  $\Rightarrow$ Yêu cầu bảo toàn và làm sắc nét thông tin chi tiết từng modality.

Vấn đề nếu không decomposition

Nếu áp dụng fusion rule đồng nhất cho toàn bộ ảnh $\Rightarrow$ mờ cạnh, mất chi tiết texture, hoặc sai lệch màu sắc.

Decomposition cho phép thiết kế **fusion rule riêng biệt** và phù hợp cho từng thành phần.

Nhóm	Phương pháp tiêu biểu
1. Multi-scale Transform	DWT, NSST, Pyramid, Guided Filter
2. Feature Decomp. (DL)	CDDFuse, DAF-Net, PSFusion
3. Diffusion-based	DDPM, DDFM, Dif-Fusion, VLM
4. Physical-Prior	Retinex, HVD
5. INN / Flow-based	FusionINN, EMMA

Ghi chú

Tài liệu này tổng hợp lý thuyết nền tảng, phân tích toán học và so sánh các phương pháp decomposition nổi bật từ **2022 đến đầu 2025**.

Đặc điểm: Nhóm phương pháp truyền thống với nền tảng toán học chặt chẽ.

Sử dụng các biến đổi toán học để phân tách ảnh thành các **dải tần số** hoặc **tỉ lệ (scale)** khác nhau.

Các phương pháp chính:

1. Discrete Wavelet Transform (DWT)
2. Non-subsampled Shearlet Transform (NSST)
3. Gaussian / Laplacian Pyramid
4. Guided Filter & Edge-Preserving Decomposition
5. Wavelet + Mamba: WMambaFuse (2025)

DWT phân tách tín hiệu 2D bằng cách áp dụng bộ lọc **low-pass** $h[n]$ và **high-pass** $g[n]$ theo cả hai chiều (hàng và cột), sau đó **downsample 2x**.

Cho ảnh $I(x, y)$, một cấp DWT tạo ra **4 sub-band**:

- **LL:** Xấp xỉ (approximation) – low-frequency, global structure
- **LH:** Chi tiết nằm ngang **HL:** Chi tiết dọc
- **HH:** Chi tiết chéo – góc, kết cấu mịn

Forward DWT cấp 1

$$
\begin{aligned}
c_{LL}(m, n) &= \sum_k \sum_l h[k]\, h[l] \cdot I(2m - k,\, 2n - l) \\
c_{LH}(m, n) &= \sum_k \sum_l g[k]\, h[l] \cdot I(2m - k,\, 2n - l)
\end{aligned} \tag{1}
$$

IDWT: Tái tạo ảnh **không mất thông tin** (perfect reconstruction) khi bộ lọc thỏa điều kiện biorthogonal.

Quy trình Fusion với DWT:

1. DWT cho từng ảnh nguồn $I_1, I_2 \rightarrow \{LL, LH, HL, HH\}$
2. Fusion sub-band LL (low-freq): **weighted average**
3. Fusion sub-band LH/HL/HH (high-freq): **max-absolute rule**:

$$F_{HH}(m,n) = \arg\max_{k \in \{1,2\}} |c_{HH}^{k}(m,n)| \tag{2}$$

4. IDWT trên các sub-band đã fusion $\rightarrow$ ảnh kết quả

Biến thể SOTA: WaveFusionNet (2024)

Tích hợp DWT vào encoder-decoder: DWT thay max-pooling. Feature wavelet feed vào attention module để tự động học fusion weight.

Ưu điểm:

- Perfect reconstruction
- Nền tảng lý thuyết chặt chẽ
- Tính toán nhanh

Nhược điểm:

- **Shift-variant** (không bất biến dịch chuyển)
- Ít hướng: chỉ 3 hướng (H, V, D)

Động lực: DWT chỉ có 3 hướng. NSST kết hợp NSCT và Shearlet để đạt phân giải **đa hướng, đa tỉ lệ** mà **không aliasing** (nhờ không downsample).

Định nghĩa Shearlet

$$\psi_{j,l,k}(x) = a^{3j/4}\,\psi\big(S_l\,A_a^j\,x - k\big) \tag{3}$$

A_a: ma trận scale anisotropic S_l: ma trận shear k: vector dịch chuyển

NSST **không downsample** $\Rightarrow$ sub-band cùng kích thước ảnh gốc $\Rightarrow$ dễ thiết kế fusion rule tại từng pixel.

Ứng dụng

NSST đặc biệt hiệu quả trong **Medical Image Fusion** (MRI–CT, PET–MRI) nhờ khả năng bắt cạnh đa hướng.

Gaussian Pyramid tạo chuỗi ảnh mờ dần: $G_0 \supset G_1 \supset \ldots \supset G_N$. Mỗi cấp thu nhỏ bằng Gaussian kernel rồi downsample 2x:

$$G_{l+1}(i,j) = \sum_{m,n} w(m,n) \cdot G_l(2i+m,\, 2j+n) \tag{4}$$

Laplacian Pyramid là sự khác biệt giữa các cấp Gaussian:

$$L_l = G_l - \text{EXPAND}(G_{l+1}) \tag{5}$$

- ◇ EXPAND: upsample + blur. Mỗi L_l chứa detail tại tỉ lệ tương ứng.
- ◇ G_N (cấp thấp nhất) là residual base image.

Octave Gaussian Pyramid (2024)

Chia pyramid thành octave và interval. Dùng **guided filter** để tăng sharpness, giảm halo artifact.

Guided Filter (He et al., 2013) – mô hình **tuyến tính cục bộ**:

$$q_i = a_k \cdot p_i + b_k, \quad \forall\, i \in \omega_k \tag{6}$$

(p_i: input, q_i: output, ω_k: cửa sổ cục bộ tại k)
Hệ số (a_k, b_k) tối thiểu hóa:

$$E(a_k, b_k) = \sum_{i \in \omega_k} \left[(a_k G_i + b_k - p_i)^2 + \epsilon \cdot a_k^2 \right] \tag{7}$$

Guided image G giúp bộ lọc **bảo toàn cạnh mạnh**.

MLGEPF (2024)

Multilevel Guided Edge-Preserving Filter: multi-level decomposition nhanh $O(n)$. Phù hợp ảnh y tế (PET–MRI, CT–MRI).

WMambaFuse kết hợp **hai module song song**:

- **WMFM** (Wavelet-domain Mamba Fusion Module): xử lý thông tin frequency
- **SAFM** (Spatial Attention Fusion Module): xử lý không gian

Kiến trúc:

- Swin Transformer encoder trích xuất feature đa tỉ lệ
- **Mamba (SSM)** được dùng thay vì self-attention truyền thống $O(n^2)$ để xử lý chuẩn token dài hiệu quả hơn ($O(n)$)

Xu hướng 2024–2025

Thay Transformer bằng Mamba/SSM trong frequency domain để giảm chi phí tính toán trên ảnh high-resolution.

Đặc điểm: Học cách phân tách **trực tiếp từ dữ liệu** thay vì dùng transform cố định.

Mạng neural tự tìm ra biểu diễn tối ưu cho fusion task.

Các phương pháp chính:

1. CDDFuse – Base-Detail Decomposition (CVPR 2023)
2. Modality-Specific / Shared Decomposition (DAF-Net, 2024)
3. Semantic Layer Decomposition (PSFusion, 2023)
4. Transformer-CNN Hybrid (DAF-Net, 2024)

CDDFuse (Correlation-Driven Dual-Branch Fusion) – một trong những mô hình **SOTA quan trọng nhất 2023**.

Kiến trúc gồm:

- **Lite Transformer (LT) Block:** Xử lý low-frequency global feature (base).
  Transformer học mối quan hệ tầm xa, phù hợp để nắm bắt cấu trúc toàn cục.
- **Invertible Neural Network (INN) Block:** Xử lý high-frequency local detail.
  INN đảm bảo thông tin detail không bị mất nhờ tính khả nghịch.
- **Correlation-Driven Loss:** Điều khiển quá trình học decomposition.

(a) Correlation Loss cho Base Features – base feature hai modality phải tương quan cao:

$$\mathcal{L}_{\text{base}} = 1 - \rho(F_{\text{base}}^{IR},\, F_{\text{base}}^{VIS}), \quad \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y} \tag{8}$$

(b) Decorrelation Loss cho Detail Features – detail feature hai modality phải **ít tương quan**:

$$\mathcal{L}_{\text{detail}} = |\rho(F_{\text{detail}}^{IR},\, F_{\text{detail}}^{VIS})| \tag{9}$$

Tổng Loss

$$\mathcal{L}_{\text{total}} = \lambda_1 \mathcal{L}_{\text{base}} + \lambda_2 \mathcal{L}_{\text{detail}} + \lambda_3 \mathcal{L}_{\text{recon}} + \lambda_4 \mathcal{L}_{\text{perception}}$$

Ý tưởng: Base features correlate cao → fuse bằng weighted avg. Detail features decorrelate → fuse bằng max/concat để giữ tính riêng biệt.

Fusion rules:

- **Base fusion:**

$$F_{\text{base}}^{F} = \frac{F_{\text{base}}^{IR} + F_{\text{base}}^{VIS}}{2} \tag{10}$$

- **Detail fusion:**

$$F_{\text{detail}}^{F} = \alpha \cdot F_{\text{detail}}^{IR} + (1 - \alpha) \cdot F_{\text{detail}}^{VIS} \tag{11}$$

  trong đó α **học từ attention module**

- **Reconstruction:** IDWT/decoder từ $(F_{\text{base}}^{F}, F_{\text{detail}}^{F}) \rightarrow$ fused image

Mục tiêu: Tách **shared content** (cấu trúc giải phẫu) và **modality-specific content** (thermal, texture riêng).

Cho encoder E_s (shared), E_m (specific), decoder D:

$$\begin{aligned} z_s^A = E_s(I^A),\ z_s^B = E_s(I^B) &\Rightarrow \text{giống nhau (shared)} \\ z_m^A = E_m(I^A),\ z_m^B = E_m(I^B) &\Rightarrow \text{khác nhau (specific)} \\ I^A = D(z_s^A,\ z_m^A) &\ \text{(reconstruction)} \end{aligned} \tag{12}$$

Loss disentanglement:

- ◇ **Cross-reconstruction:** $I^{A\to B} = D(z_s^A, z_m^B)$ phải giống I^B
- ◇ **MK-MMD:** $\mathrm{MMD}^2(X, Y) = \|\mu_X - \mu_Y\|_{\mathcal{H}}^2$

DAF-Net (2024):

- Dùng **Multi-Kernel MMD** trong base encoder để align latent space IR và VIS
- INN-based detail encoder tách riêng texture từng modality
- Cross-attention giữa shared và specific features trước khi fusion

PSFusion (2023) – Semantic Layer Decomposition:

- Phân tách theo semantic levels dựa trên độ sâu trong mạng backbone (ResNet)
- Layer nông (early) $\rightarrow$ low-level feature (cạnh, màu sắc)
- Layer sâu (late) $\rightarrow$ high-level semantic feature (object, class)

$$
\begin{aligned}
F_l &= E_l(I), \quad l = 1..L \\
F^{\text{fused}} &= \sum_l w_l \cdot \text{Fusion}(F_l^{IR}, F_l^{VIS})
\end{aligned} \tag{13}
$$

Mô hình hybrid dùng Transformer và CNN **song song**:

- **Transformer branch:** self-attention trên patch → global feature → **base component**
- **CNN branch:** conv layers → local feature → **detail component**
- **Cross-branch fusion:** cross-attention giữa hai nhánh để bổ sung thông tin

Ý nghĩa

Kết hợp ưu điểm của Transformer (global context) và CNN (local detail) để tạo ra phân tách base-detail hiệu quả hơn.

Đặc điểm: Không phân tách ảnh theo cách truyền thống mà formulate fusion như bài toán **conditional generation** hoặc **Bayesian inference** trong không gian latent của mô hình sinh.

Các phương pháp chính:

1. DDPM – Denoising Diffusion Probabilistic Models
2. DDFM – Fusion như Bayesian Posterior Sampling (ICCV 2023)
3. Dif-Fusion – Frequency-domain Diffusion (2023)
4. VLM-Guided Fusion (ICML 2024)

Forward process: Thêm Gaussian noise vào x_0 qua T bước:

$$q(x_t|x_{t-1}) = \mathcal{N}\Big(x_t;\ \sqrt{1-\beta_t}\, x_{t-1},\ \beta_t \mathsf{I}\Big) \tag{14}$$

Closed form: $q(x_t|x_0) = \mathcal{N}\big(x_t;\ \sqrt{\bar{\alpha}_t}\, x_0,\ (1-\bar{\alpha}_t)\,\mathsf{I}\big)$, với $\bar{\alpha}_t = \prod_{s=1}^{t}(1-\beta_s)$

Reverse process: Học loại noise để tái tạo ảnh:

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1};\ \mu_\theta(x_t,t),\ \Sigma_\theta(x_t,t)) \tag{15}$$

Training Loss:

$$\mathcal{L}_{\text{DDPM}} = \mathbb{E}_{x_0,\epsilon,t}\Big[\big\|\epsilon - \epsilon_\theta\big(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon,\ t\big)\big\|^2\Big] \tag{16}$$

DDFM (ICCV 2023 Oral) – fusion như tính posterior:

$$p(x_F|I_{IR}, I_{VIS}) \propto p(x_F) \cdot p(I_{IR}, I_{VIS}|x_F) \tag{17}$$

Phân ra bằng **EM algorithm**:

- **Subproblem 1:** $\nabla_{x_t} \log p_\theta(x_t)$ – score function của pre-trained DDPM (**không cần re-train**)
- **Subproblem 2:** $\nabla_{x_t} \log p(I_{IR}, I_{VIS}|x_t)$ – hierarchical Bayesian:

$$\log p(I|x_t) = \sum_i \log p(I_i|z_i) + \log p(z_i|x_t) \tag{18}$$

z_i: latent variable, tối ưu bằng EM (E-step estimate z_i, M-step update gradient).

Đặc điểm

Ưu: Zero-shot, không cần training data. **Nhược:** Inference chậm (T denoising steps).

Dif-Fusion (2023):

- Phân tách ảnh theo **frequency domain** trước khi áp dụng diffusion
- Low-frequency fusion bằng **weighted average**
- High-frequency enhance bằng **guided diffusion process**
- Bảo toàn color fidelity và tăng sharpness đồng thời

VLM-Guided Fusion (ICML 2024):

- Sử dụng Vision-Language Model (CLIP, BLIP-2) để hướng dẫn decomposition và fusion
- Text prompt (ví dụ: "*preserve pedestrian thermal signature*") được encode thành text embedding
- Cross-attend với image feature để điều khiển fusion weight
- Decomposition trở nên **task-adaptive**

Retinex (Land & McCann, 1971) mô hình hóa ảnh quan sát I như **tích** của hai thành phần:

$$I(x, y) = L(x, y) \cdot R(x, y) \tag{19}$$

- $L(x, y)$: **illumination map** – ánh sáng nền, biến đổi chậm
- $R(x, y)$: **reflectance map** – nội dung thực, màu sắc và cạnh

Trong log domain: $\log I = \log L + \log R$

Illumination L ước lượng bằng **Total Variation minimization**:

$$L^* = \arg\min_L \left\{ \| \log I - \log L \|^2 + \lambda \cdot TV(\log L) \right\} \tag{20}$$

Bài toán: IR có thông tin thermal reliable, cao tương phản. VIS có thông tin màu sắc.

Sau Retinex decomposition:

- ◇ Lấy illumination L từ IR (IR có độ tương phản cao và nhất quán)
- ◇ Lấy reflectance R từ VIS (VIS có thông tin màu sắc)
- ◇ Tái tạo:

$$I_F = L_{IR} \cdot R_{VIS} \quad \text{(enhanced, colorful, high-contrast)} \tag{21}$$

HVD là phương pháp **adaptive decomposition** không cần basis function cố định.

Tín hiệu $f(t)$ biểu diễn là tổng các thành phần dao động:

$$f(t) = \sum_k A_k(t) \cdot \cos(\phi_k(t)) + r(t) \tag{22}$$

($A_k(t)$: instantaneous amplitude, $\phi_k(t)$: instantaneous phase)
Phép biến đổi Hilbert tính analytical signal:

$$f_a(t) = f(t) + i \cdot \mathcal{H}\{f(t)\} = A(t) \cdot e^{i\phi(t)} \tag{23}$$

So sánh với EMD

HVD **không dùng sifting process** nên ít mode mixing. Decompose ảnh 2D thành spatial frequency components **non-stationary**.

Ưu: Không cần cut-off frequency, thích nghi local structure. Phù hợp ảnh texture phức tạp.

Sử dụng tính **khả nghịch (invertibility)** như ràng buộc kiến trúc, đảm bảo **không có thông tin nào bị mất**.

$\Rightarrow$ Quan trọng trong y tế (interpretability, reconstruction).

RealNVP (Dinh et al., 2017) – Affine Coupling Layer:

Cho input $\mathrm{x} = (x_1, x_2)$:

$$\begin{aligned} y_1 &= x_1 \\ y_2 &= x_2 \odot \exp(s(x_1)) + t(x_1) \end{aligned} \tag{24}$$

Trong đó $s(\cdot)$ và $t(\cdot)$ là các mạng neural tùy ý (**không cần khả nghịch**).

Biến đổi ngược:

$$\begin{aligned} x_1 &= y_1 \\ x_2 &= (y_2 - t(y_1)) \odot \exp(-s(y_1)) \end{aligned} \tag{25}$$

Jacobian là triangular $\Rightarrow$ determinant tính dễ dàng:
$\log |\det J| = \sum s(x_1)$

Change of Variables Formula:
Với INN $f : x \to z$, likelihood của dữ liệu:

$$\log p(x) = \log p_Z(f(x)) + \log \left| \det \left(\frac{\partial f}{\partial x} \right) \right| \tag{26}$$

Trong đó p_Z là prior (Gaussian). Training **maximize log-likelihood** này.

Haar Wavelet Downsampling trong INN:
Thay vì strided convolution (mất thông tin), nhiều INN dùng Haar wavelet downsampling để squeeze spatial dimensions vào channel dimension:

$$x \in \mathbb{R}^{H \times W \times C} \to z \in \mathbb{R}^{H/2 \times W/2 \times 4C} \tag{27}$$

Đây là phép biến đổi **khả nghịch**, preserve thông tin qua tất cả layers.

FusionINN tích hợp đồng thời image decomposition và fusion vào một **normalizing flow end-to-end**:

$$(z_s,\, z_A,\, z_B) = f_{INN}(I^A,\, I^B) \tag{28}$$

Trong đó z_s là shared latent, z_A, z_B là modality-specific latents.

Fused image:

$$I^F = f_{INN}^{-1}(z_s,\, 0,\, 0) \tag{29}$$

Tái tạo source images:

$$\hat{I}^A = f_{INN}^{-1}(z_s,\, z_A,\, 0) \tag{30}$$

Ý nghĩa y tế

Khả năng tái tạo source images từ fused image là đặc tính quan trọng trong ứng dụng y tế.

Training Objective:

- **Reconstruction loss:** $\|I^A - \hat{I}^A\|_1 + \|I^B - \hat{I}^B\|_1$
- **Fusion quality:** perceptual loss + gradient loss trên I^F
- **Disentanglement:** KL divergence align z_s; khuyến khích z_A, z_B orthogonal

EMMA – Equivariant Multi-Modal Alignment (CVPR 2024):

- Sử dụng **equivariant network** để học phép biến đổi giữa modalities
- Equivariance đảm bảo: nếu ảnh bị transform (rotate, flip), feature map cũng transform tương ứng
- $\Rightarrow$ Alignment tốt hơn giữa IR và VIS khi có misalignment

Phương pháp	**Nền tảng**	**Ưu điểm**	**Nhược điểm**
DWT/Wavelet	Phân tích tần số	Perfect reconst., nhanh	Shift-variant, ít hướng
NSST	Shearlet, ko downsample	Ko aliasing, nhiều hướng	Chi phí tính toán cao
Laplacian Pyr.	Gaussian blur + diff.	Đơn giản, trực quan	Halo artifact
Guided Filter	M.h. tuyến tính cục bộ	Bảo toàn cạnh, $O(n)$	Ko multi-scale mặc định
CDDFuse	Corr. loss + INN + Transf.	SOTA, end-to-end, đa task	Cần training data lớn
DDFM	DDPM, Bayesian, EM	Zero-shot, chất lượng cao	Inference chậm
Retinex	Mô hình sinh ảnh (L·R)	Diễn giải được, low-light	Nhạy với ảnh nhiễu
HVD	Hilbert, adaptive	Adaptive, ko basis cố định	Phức tạp, ít benchmark
FusionINN	Normalizing flow	Fully invertible, tái tạo	Memory lớn
WMambaFuse	Mamba SSM + Wavelet	Hiệu quả $O(n)$, SOTA 2025	Mới, ít đánh giá

Dataset	**Modality**	**Task**	**Ghi chú**
TNO	IR + VIS	IR-VIS Fusion	Military, 9 pairs
RoadScene	IR + VIS	IR-VIS Fusion	Street, 221 pairs
MSRS	IR + VIS	Fusion + Det.	SOTA benchmark
MFNet	IR + VIS	Fusion + Seg.	Semantic labels
Harvard Med.	CT+MRI+PET	Medical Fusion	Brain scans
LLVIP	IR + VIS	Low-light	16836 pairs

Metric	**Công thức**	**Ý nghĩa**
EN (Entropy)	$H = -\sum p_i \log p_i$	Độ phong phú thông tin
SF (Spatial Freq.)	$SF = \sqrt{RF^2 + CF^2}$	Mức biến đổi k.gian
MI (Mutual Info.)	$\sum p(f,s) \log \frac{p(f,s)}{p(f)p(s)}$	TT chia sẻ fused-source
SSIM	$l \cdot c \cdot s$	Độ tương đồng cấu trúc
VIF	HVS channel model	Visual Info. Fidelity
LPIPS	Deep feat. distance	Perceptual similarity
mAP	Precision-Recall AUC	Downstream detection

Trích dẫn: *Zhao, Zixiang, et al. "CDDFuse: Correlation-driven dual-branch feature decomposition for multi-modality image fusion."CVPR 2023.*

Kết quả **chính thức từ repository GitHub** của tác giả trên tập dữ liệu **TNO Dataset**:

Phương pháp	**EN (↑)**	**SD (↑)**	**SF (↑)**	**MI (↑)**	**SCD (↑)**	**VIF (↑)**	**Qabf (↑)**	**SSIM (↑)**
DenseFuse (2018)	–	–	–	–	–	–	–	–
U2Fusion (2020)	–	–	–	–	–	–	–	–
TarDAL (2021)	–	–	–	–	–	–	–	–
CDDFuse (Ours)	**7.12**	**46.0**	**13.15**	**2.19**	**1.76**	**0.77**	**0.54**	**1.03**

Nguồn: github.com/Zhaozixiang1228/MMIF-CDDFuse (official test script output, Table 1 paper gốc).

Nhận xét từ tác giả

Nhờ Correlation-driven loss và kiến trúc nhánh kép (INN + Transformer), CDDFuse vượt trội hơn hẳn các phương pháp trước đó về khả năng bảo toàn thông tin nền (EN, MI) và cấu trúc chi tiết (SSIM).

Trích dẫn: *Zhao, Zixiang, et al. "DDFM: Denoising diffusion model for multi-modality image fusion."ICCV 2023 (Oral).*

Kết quả từ bài báo gốc DDFM trên tập **TNO Dataset** (DDFM không đánh giá SF):

Phương pháp	**EN (↑)**	**SD (↑)**	**MI (↑)**	**VIF (↑)**	**SSIM (↑)**
SDNet (2021)	–	–	–	–	–
DeFusion (2022)	7.06	40.70	2.04	0.64	0.92
CDDFuse (conc.)	–	–	–	–	–
DDFM (Ours)	**7.06**	**51.42**	**2.21**	**0.81**	**0.95**

Nguồn: bảng Table 1, DDFM ICCV 2023 paper. CDDFuse (concurrent, cùng nhóm tác giả) không có trong bảng so sánh chính thức. Metric SF không được báo cáo.

Nhận xét từ tác giả

DDFM vận hành dưới dạng zero-shot Bayesian inference. Với prior phân phối mạnh mẽ từ DDPM, phương pháp này sinh ra ảnh có SD và VIF vượt trội rất rõ so với DeFusion, đặc biệt hiệu quả về chất lượng thị giác tự nhiên.

Trích dẫn: *Tang, Linfeng, et al. "Rethinking the necessity of image fusion in high-level vision tasks: PSFusion."Information Fusion, vol.99, 101870, 2023.*

Trên tập **MSRS Dataset** (361 cặp ảnh), PSFusion báo cáo các metric fusion + segmentation:

Phương pháp	**EN (↑)**	**SD (↑)**	**SF (↑)**	**SCD (↑)**	**VIF (↑)**	**mIoU % (↑)**
SeAFusion (2022)	–	–	–	–	–	–
TarDAL (2021)	–	–	–	–	–	–
PSFusion (Ours)	**6.839**	**46.291**	**14.207**	**1.811**	**1.043**	**80.38**

Nguồn: arXiv:2303.09050, bảng kết quả trên MSRS (361 cặp). mIoU=80.38% với segmentor SegNeXt. Metric của paper: EN, SD, SF/AG, SCD, VIF + mIoU (không phải mAP detection).

Nhận xét từ tác giả

PSFusion chia sẻ semantic encoder giữa nhánh fusion và segmentation. Kết quả mIoU **80.38%** (SegNeXt) vượt trội SeAFusion, chứng minh việc tích hợp semantic injection cải thiện cả chất lượng ảnh (SF, VIF) lẫn hiệu năng downstream segmentation.

Trích dẫn: *Moghtaderi et al. "Advancing multimodal medical image fusion via multilevel guided filtering."Royal Society Open Science, 11(4), 2024.*

Đánh giá trên 40 cặp ảnh não bộ **MRI-PET / MRI-SPECT** dùng metric đặc thù y tế:

Phương pháp	**FMI (↑)**	**SCD (↑)**	**Qabf (↑)**	Q_y **(↑)**	**SSIM (↑)**
MST-SR (baseline)	–	–	–	–	–
NSCT+SR (2020)	–	–	–	–	–
MLGEPF (Ours)	–	–	–	–	–

Nguồn: Royal Society Open Science, DOI: 10.1098/rsos.231762. Metric thực tế của paper: FMI, SCD, Qabf, Q_y (edge), SSIM — **không phải** EN/MI/SF như slide cũ. Số liệu cụ thể yêu cầu truy cập trực tiếp PDF (paywall).

Nhận xét từ tác giả

Bộ lọc **Multilevel Guided Edge-Preserving Filter** (MLGEPF) phân tách ảnh thành 3 sublayer độc lập. Dùng PCNN (structure tensor) + maximum fusion giúp bảo toàn biên cấu trúc Q_y và tương quan thông tin SCD vượt trội các phương pháp truyền thống với độ phức tạp $O(n)$.

1. **Hybrid:** Wavelet+Transformer, INN+Diffusion, Retinex+DL
2. **Task-driven Decomposition:**

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{fusion}} + \lambda \mathcal{L}_{\text{seg}} + \mu \mathcal{L}_{\text{det}} \tag{31}$$

3. **Efficient Architecture – Mamba / SSM:**

$$h'(t) = A(t)h(t) + B(t)x(t), \quad y(t) = C(t)h(t) \tag{32}$$

A, B, C: time-varying matrices (selective) – $O(n)$ thay vì $O(n^2)$.

4. **Foundation Model & Zero-shot:** SAM, CLIP, Stable Diffusion làm backbone fusion không cần fine-tune.
5. **Interpretable & Medical:** FusionINN cho phép "undo" fusion, kiểm chứng đóng góp từng modality.

Image decomposition đóng vai trò **nền tảng** trong Image Fusion SOTA.

Các nhận định chính:

- **Không có phương pháp tối ưu toàn diện:** Multi-scale nhanh; DL chất lượng hơn; Diffusion tốt nhất visual quality nhưng chậm.
- **Frequency split (low/high) là mẫu số chung** của hầu hết framework.
- **INN và invertibility ngày càng quan trọng** – đặc biệt trong y tế.
- **Diffusion model mở paradigm mới:** Fusion như Bayesian inference, zero-shot.
- **Xu hướng 2025:** Mamba + Wavelet + Task-aware loss.

1. Zhao Z., et al. CDDFuse. *CVPR 2023*.
2. Zhao Z., et al. DDFM. *ICCV 2023 (Oral)*.
3. Tang L., et al. PSFusion. *IEEE TIP 2023*.
4. He K., et al. Guided Image Filtering. *IEEE TPAMI, 2013*.
5. Dinh L., et al. RealNVP. *ICLR 2017*.
6. Ho J., Jain A., Abbeel P. DDPM. *NeurIPS 2020*.
7. Gu A., Dao T. Mamba. *arXiv 2023*.
8. WMambaFuse. *arXiv 2025*.
9. FusionINN. *IEEE TIP 2024*.
10. DAF-Net. *ICCV 2024*.
11. MLGEPF. *2024*.
12. EMMA. *CVPR 2024*.
13. Dif-Fusion. *IEEE TIP 2023*.
14. Land E.H., McCann J.J. Retinex Theory. *JOSA, 1971*.

CẢM ƠN THẦY VÀ CÁC BẠN

ĐÃ LẮNG NGHE!

Hỏi và đáp (Q&A)